ANALITIK DAN VISUALISASI DATA
ANALISIS TRANSAKSI KATALOG KONTEN NETFLIX

Disusun oleh:

Brendhen Canafaro Lie (2509116033)

Program Studi Sistem Informasi

Fakultas Teknik

Universitas Mulawarman

2026

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas rahmat dan karunia-Nya sehingga laporan akhir mata kuliah Analitik dan Visualisasi Data ini dapat diselesaikan dengan baik.

Laporan ini disusun sebagai bentuk pertanggungjawaban atas proyek analisis data yang telah dilaksanakan selama perkuliahan. Proyek ini berfokus pada Exploratory Data Analysis (EDA) terhadap dataset Netflix Titles yang bersumber dari Kaggle, mencakup 8.807 judul konten film dan serial TV yang tersedia di platform Netflix hingga tahun 2021.

Melalui laporan ini, penulis berupaya menyajikan proses analisis data secara sistematis, mulai dari pemahaman bisnis, pemahaman data, persiapan data, hingga visualisasi dan penyusunan insight yang actionable. Setiap tahapan dilakukan dengan cermat agar menghasilkan temuan yang akurat dan bermanfaat.

Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi perbaikan di masa mendatang. Semoga laporan ini dapat memberikan manfaat bagi pembaca, khususnya bagi pihak yang memerlukan referensi dalam analisis data platform streaming digital.

Samarinda, Maret 2026

Penulis

DAFTAR ISI

KATA PENGANTAR 1
DAFTAR ISI 2
DAFTAR GAMBAR 3
DAFTAR TABEL 4
BAB I PENDAHULUAN 5
1.1. Latar Belakang 5
1.2. Tujuan Analisis 5
BAB II PEMBAHASAN 6
2.1. Business Understanding 6
2.1.1. Business Objective 6
2.1.2. Assess Situation 6
2.1.3. Analytic Goals & Project Plan 7
2.2. Data Understanding 8
2.2.1. Import Library 8
2.2.2. Memuat Dataset 8
2.2.3. Deskripsi Data 9
2.2.4. Verifikasi Kualitas Data 12
2.3.1. Menyimpan Dataset Bersih 16
2.4.1. Movie vs TV Show (Bar Chart) 17
2.4.2. Top 10 Genre Terpopuler Transaksi per Negara (Bar Chart) 18
2.4.3. Proporsi Negara Produksi (Pie Chart) 20
2.4.4. Top 10 Negara Produksi (Bar Chart) 22
2.4.5. Distribusi Tahun Rilis Konten (Histogram) 23
2.4.6. Tren Penambahan Konten per Tahun (Line Chart) 25
2.4.7. Rating Konten berdasarkan Tipe (Grouped Bar Chart) 26
2.4.8. Heatmap Genre vs Rating 28
BAB III PENUTUP 30
3.1. Kesimpulan 30
3.2. Saran 30

DAFTAR GAMBAR

Gambar 2.1 Memuat Dataset 9
Gambar 2.2 Informasi Dasar 10
Gambar 2.3 informasi Deskriptif 12
Gambar 2.4 Missing Values 13
Gambar 2.5 Incosistent Values 13
Gambar 2.6 Pengecekan Baris Duplikat 14
Gambar 2.7 Outliers Value 15
Gambar 2.8 Jumlah Movie vs TV Show di Netflix 18
Gambar 2.9 Top 10 Genre Terpopuler di Netflix 19
Gambar 2.10 Komposisi Negara Produksi Konten Netflix 21
Gambar 2.11 Top 10 Negara Produksi Konten Netflix 22
Gambar 2.12 Distribusi Tahun Rilis Konten Netflix (1990-2021) 24
Gambar 2.13 Tren Penambahan Konten Netflix per Tahun 25
Gambar 2.14 Distribusi Rating berdasarkan Tipe Konten 27
Gambar 2.15 Jumlah Konten per Genre dan Rating 29

DAFTAR TABEL

Tabel 2.1 Ciri-Ciri Dataset 6
Tabel 2.2 Informasi Lanjutan Dataset 10
Tabel 2.3 Tabel Strategi Pembersihan 15

BAB I
PENDAHULUAN

1.1. Latar Belakang

Perkembangan industri hiburan digital yang pesat telah mendorong pertumbuhan platform streaming secara global. Netflix, sebagai salah satu platform streaming terbesar di dunia, telah mengumpulkan katalog konten yang sangat besar sejak berdirinya hingga saat ini. Setiap konten yang tersedia menyimpan informasi berharga terkait preferensi penonton, strategi produksi, dan tren industri hiburan digital.

Dalam ekosistem digital yang semakin kompetitif, kemampuan untuk memahami dan menganalisis data katalog konten menjadi keunggulan strategis yang krusial. Pihak yang mampu mengekstrak insight dari data katalog akan lebih adaptif dalam memahami tren konten dan mengambil keputusan yang tepat sasaran.

Dataset Netflix Titles dari Kaggle menyediakan informasi lengkap mengenai 8.807 judul konten yang tersedia di platform Netflix hingga tahun 2021. Dataset ini mencakup berbagai dimensi data, mulai dari jenis konten (Movie/TV Show), genre, negara produksi, tanggal penambahan, tahun rilis, rating usia, hingga durasi. Dataset ini merepresentasikan kondisi data nyata yang mewakili strategi konten sebuah platform streaming global berskala besar.

Analisis terhadap dataset ini memungkinkan identifikasi dominasi tipe konten, tren penambahan konten dari waktu ke waktu, pemahaman tentang genre yang paling diminati, serta pemetaan distribusi negara produksi. Temuan-temuan ini diharapkan dapat memberikan wawasan yang berguna bagi pemangku kepentingan di industri hiburan digital dalam merancang strategi konten yang lebih efektif.

1.2. Tujuan Analisis

Berdasarkan latar belakang yang telah dibahas, tujuan dari analisis data ini adalah:

1. Membandingkan distribusi konten berdasarkan tipe (Movie vs TV Show) dan mengidentifikasi genre yang paling dominan tersedia di katalog Netflix.
2. Menganalisis komposisi dan kontribusi negara produksi terhadap total konten Netflix untuk memahami sebaran produksi konten secara geografis.
3. Menganalisis distribusi tahun rilis konten dan tren penambahan konten per tahun untuk memahami pola pertumbuhan platform Netflix dari waktu ke waktu.
4. Mengeksplorasi hubungan antara rating konten dengan tipe dan genre untuk memahami segmen usia penonton yang paling banyak disasar oleh Netflix.

BAB II
PEMBAHASAN

2.1. Business Understanding

2.1.1. Business Objective

Industri streaming digital global terus berkembang pesat, menghasilkan kompetisi yang semakin ketat antar platform. Di balik jutaan konten yang tersedia tersimpan pola-pola penting yang apabila dianalisis dengan tepat, dapat menjadi keunggulan kompetitif bagi pelaku industri dalam memahami selera pasar dan mengambil keputusan strategis.

Proyek analisis ini memanfaatkan dataset Netflix Titles yang mencakup 8.807 judul konten dari platform Netflix dengan rentang periode penambahan konten dari tahun 2008 hingga 2021. Dataset ini merekam berbagai dimensi konten mulai dari jenis konten, genre, negara produksi, rating usia, hingga durasi dari berbagai negara di seluruh dunia.

2.1.2. Assess Situation

Platform streaming modern mengakumulasi ribuan judul konten setiap tahunnya, di mana setiap konten menyimpan informasi berharga yang dapat dimanfaatkan sebagai dasar pengambilan keputusan bisnis yang strategis. Tanpa adanya analisis yang terstruktur, data-data tersebut hanya menjadi catatan mentah tanpa nilai tambah.

Melalui analisis data katalog secara menyeluruh, dapat dipahami pola distribusi konten, mengidentifikasi genre dan negara produksi yang paling dominan, serta memetakan tren pertumbuhan platform dari waktu ke waktu. Berikut merupakan ciri-ciri dataset yang dapat dilihat:

Tabel 2.1 Ciri-Ciri Dataset

No.	Ciri-Ciri Dataset	
1.	Sumber Data	Dataset Netflix Movies and TV Shows dari Kaggle (https://www.kaggle.com/datasets/shivamb/netflix-shows)
2.	Kondisi Data	Memiliki 8.807 baris dan 12 kolom. Terdapat missing values pada beberapa kolom, terutama kolom director (29.9%). Tidak ada data duplikat.

3.	Kendala	Kolom rating memiliki 3 nilai salah berupa durasi menit. Kolom date_added bertipe object perlu dikonversi ke datetime. Kolom director, cast, dan country memiliki missing values cukup banyak.

2.1.3. Analytic Goals & Project Plan

Tujuan analisis dari proyek ini dirancang untuk menghasilkan insight yang actionable bagi pemahaman strategi konten Netflix melalui empat tujuan analisis utama:

a. Analisis Perbandingan Tipe Konten dan Genre (Comparison)

Membandingkan jumlah Movie vs TV Show serta mengidentifikasi 10 genre terpopuler dalam katalog Netflix. Hasil analisis ini diharapkan membantu memahami strategi konten Netflix dan peluang bagi kreator konten.

b. Analisis Komposisi Negara Produksi (Composition)

Mengidentifikasi negara-negara yang paling banyak memproduksi konten Netflix baik secara proporsi maupun jumlah absolut. Temuan ini akan menjadi dasar pemahaman dominasi geografis konten di platform.

c. Analisis Distribusi dan Tren Konten (Distribution)

Menganalisis distribusi tahun rilis konten dan tren penambahan konten per tahun untuk memahami pertumbuhan platform Netflix dan dampak pandemi COVID-19.

d. Analisis Hubungan Rating dengan Tipe dan Genre (Relationship)

Menganalisis pola rating berdasarkan tipe konten dan genre menggunakan grouped bar chart dan heatmap untuk memahami segmen audiens yang disasar Netflix.

Rencana proyek ini dilaksanakan secara sistematis melalui lima tahapan utama:

a. Business Understanding

Mendefinisikan tujuan bisnis dan pertanyaan analisis.

b. Data Understanding

Eksplorasi awal dataset untuk memahami struktur dan kualitas data.

c. Data Preparation

Membersihkan dan mentransformasi data mentah menjadi dataset yang siap dianalisis.

d. Visualisasi (EDA)

Membangun 8 visualisasi informatif dengan insight dan rekomendasi tindakan menggunakan Python (Matplotlib & Seaborn) di Google Colab.

e. Pelaporan & Kesimpulan

Menyusun laporan akhir yang komprehensif berisi ringkasan temuan, insight yang diperoleh, serta rekomendasi strategis.

2.2. Data Understanding

Data Understanding adalah tahap kedua setelah Business Understanding. Pada tahap ini, data dipahami, dianalisis, dan dideskripsikan secara menyeluruh agar dapat dijadikan dasar visualisasi dan pengambilan keputusan yang akurat.

2.2.1. Import Library

Langkah pertama adalah dengan memuat library tools yang nantinya digunakan.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set(style='whitegrid', font_scale=1.1)
plt.rcParams['figure.dpi'] = 100
pd.set_option('display.max_columns', 20)
```

2.2.2. Memuat Dataset

Dataset dimuat menggunakan library Pandas pada Python:

```
file = '/content/netflix_titles(Bersih).csv'
df = pd.read_csv(file)

# Konversi date_added ke datetime & ekstrak fitur tambahan
df['date_added'] = pd.to_datetime(df['date_added'].str.strip(), format='%B %d, %Y', errors='coerce')
df['year_added']  = df['date_added'].dt.year
df['month_added'] = df['date_added'].dt.month

# Ekstrak negara utama dari kolom country
df['primary_country'] = df['country'].fillna('Unknown').str.split(',').str[0].str.strip()

df.head()
```

	show_id	type	title	director	cast	count
0	s1	Movie	Dick Johnson Is Dead	Kirsten Johnson	NaN	Unit Stat
1	s2	TV Show	Blood & Water	NaN	Ama Qamata, Khosi Ngema, Gail Mabalane, Thaban...	Sou Afri
2	s3	TV Show	Ganglands	Julien Leclercq	Sami Bouajila, Tracy Gotoas, Samuel Jouy, Nabi...	Na
3	s4	TV Show	Jailbirds New Orleans	NaN	NaN	Na
4	s5	TV Show	Kota Factory	NaN	Mayur More, Jitendra Kumar, Ranjan Raj, Alam K...	Ind

Gambar 2.1 Memuat Dataset

Program di atas memuat data dari file CSV ke dalam DataFrame df. Hasil menunjukkan dataset memiliki 8.807 baris dan 12 kolom atribut. Setelah dimuat, dilakukan konversi kolom date_added ke format datetime serta ekstraksi kolom year_added, month_added, dan primary_country untuk keperluan analisis.

2.2.3. Deskripsi Data

Dari sebuah dataset terdapat informasi yang bisa dicari untuk menjelaskan tentang isi dan ciri dataset tersebut. Informasi deskripsi data mencakup sumber data, jumlah data, jenis variabel, dan lainnya. Berikut deskripsi data yang dapat diambil dari dataset Netflix Titles:

a. Informasi Dasar

Informasi dasar dari sebuah dataset yang bisa berupa data type, jumlah baris kolom, data kosong, dan lainnya.

```
# Informasi tipe data dan jumlah non-null
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8807 entries, 0 to 8806
Data columns (total 12 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   show_id       8807 non-null   object
 1   type          8807 non-null   object
 2   title         8807 non-null   object
 3   director      6173 non-null   object
 4   cast          7982 non-null   object
 5   country       7976 non-null   object
 6   date_added    8797 non-null   object
 7   release_year  8807 non-null   int64
 8   rating        8803 non-null   object
 9   duration      8804 non-null   object
 10  listed_in     8807 non-null   object
 11  description   8807 non-null   object
dtypes: int64(1), object(11)
memory usage: 825.8+ KB
```

Gambar 2.2 Informasi Dasar

Program di atas digunakan untuk menampilkan informasi dasar dari dataset. Dari output tersebut diketahui dataset ini memiliki 8.807 baris dan 12 kolom, dengan 11 kolom bertipe object dan 1 kolom bertipe int64 (release_year).

b. Informasi Lanjutan

Informasi lanjutan adalah informasi yang bersifat spesifik dan lebih jelas terhadap kolom-kolom di dalam dataset:

Tabel 2.2 Informasi Lanjutan Dataset

No.	Kolom	Tipe Data	Deskripsi
1	show_id	object	ID unik untuk setiap konten di Netflix
2	type	object	Jenis konten: Movie atau TV Show
3	title	object	Judul konten
4	director	object	Nama sutradara (dapat kosong untuk TV Show)

5	cast	object	Daftar nama pemain utama
6	country	object	Negara produksi konten
7	date_added	object	Tanggal konten ditambahkan ke platform Netflix
8	release_year	int64	Tahun rilis konten
9	rating	object	Rating usia penonton (TV-MA, R, PG-13, dll)
10	duration	object	Durasi film (menit) atau jumlah season untuk series
11	listed_in	object	Genre atau kategori konten (bisa lebih dari satu genre)
12	description	object	Sinopsis atau ringkasan cerita konten

c. Informasi Statistik Deskriptif

Informasi statistik deskriptif memuat beberapa informasi yang bisa diambil dari kolom-kolom numerik.

```
# Statistik deskriptif semua kolom
df.describe(include="all")
```

	show_id	type	title	director	cast	
count	8807	8807	8807	6173	7982	
unique	8807	2	8807	4528	7692	
top	s8807	Movie	Zubaan	Rajiv Chilaka	David Attenborough	Uni
freq	1	6131	1	19	19	
mean	NaN	NaN	NaN	NaN	NaN	
std	NaN	NaN	NaN	NaN	NaN	
min	NaN	NaN	NaN	NaN	NaN	
25%	NaN	NaN	NaN	NaN	NaN	
50%	NaN	NaN	NaN	NaN	NaN	
75%	NaN	NaN	NaN	NaN	NaN	
max	NaN	NaN	NaN	NaN	NaN	

Gambar 2.3 informasi Deskriptif

Gambar diatas menunjukkan beberapa kolom-kolom numerik yang menampilkan mean, frekuensi, jumlah dan lain-lainnya.

2.2.4. Verifikasi Kualitas Data

Verifikasi kualitas data adalah proses untuk memastikan data layak dianalisis. Proses ini mengecek apakah data sudah lengkap, akurat, dan konsisten dengan melihat data hilang, tipe data, dan nilai aneh. Tujuannya agar hasil analisis tidak menyesatkan.

a. Missing Values

```
# Persentase missing values per kolom
missing_pct = pd.DataFrame(
    df.isnull().sum() / len(df) * 100,
    columns=['Null Ratio (%)']
).round(2)
missing_pct['Jumlah Null'] = df.isnull().sum()
print(missing_pct)
```

```
               Null Ratio (%)  Jumlah Null
show_id                 0.00            0
type                    0.00            0
title                   0.00            0
director               29.91         2634
cast                    9.37          825
country                 9.44          831
date_added              0.11           10
release_year            0.00            0
rating                  0.05            4
duration                0.03            3
listed_in               0.00            0
description             0.00            0
```

Gambar 2.4 Missing Values

Interpretasi Missing Values:

- Kolom director memiliki missing value tertinggi sebesar ~29.9% — hal ini wajar karena banyak konten TV Show yang tidak memiliki satu sutradara spesifik.
- Kolom cast dan country masing-masing memiliki ~9.4% nilai kosong.
- Kolom penting seperti title, type, listed_in, release_year, dan description tidak memiliki missing value (0%) — data inti aman untuk dianalisis.

b. Inconsistent Values

```
# Cek nilai unik pada kolom rating
print("Unique values di kolom 'rating':")
print(df['rating'].unique())
print("\nNilai tidak valid (seharusnya di kolom 'duration'):")
print(df[df['rating'].isin(['74 min', '84 min', '66 min'])][['title', 'type', 'rating', 'duration']])
```

```
Unique values di kolom 'rating':
['PG-13' 'TV-MA' 'PG' 'TV-14' 'TV-PG' 'TV-Y' 'TV-Y7' 'R' 'TV-G' 'G'
 'NC-17' '74 min' '84 min' '66 min' 'NR' nan 'TV-Y7-FV' 'UR']

Nilai tidak valid (seharusnya di kolom 'duration'):
                                  title   type  rating duration
5541                     Louis C.K. 2017  Movie  74 min      NaN
5794                Louis C.K.: Hilarious  Movie  84 min      NaN
5813  Louis C.K.: Live at the Comedy Store  Movie  66 min      NaN
```

Gambar 2.5 Incosistent Values

Temuan: Terdapat 3 baris di kolom rating yang berisi nilai durasi seperti '74 min', '84 min', '66 min'. Nilai-nilai ini seharusnya berada di kolom duration. Ini adalah contoh dirty data yang perlu dibersihkan.

c. Duplicated Values

```
duplikat = df[df.duplicated()]
print(f"Jumlah baris duplikat: {len(duplikat)}")
    print("Tidak ada data duplikat!" if len(duplikat) == 0 else duplikat)
```

```
Jumlah baris duplikat: 0
✅ Tidak ada data duplikat!
```

Gambar 2.6 Pengecekan Baris Duplikat

Dari hasil gambar diatas, tidak ditemukan baris duplikat sama sekali dalam dataset. Dataset ini bersih dari data duplikat.

d. Outliers Values

Pada tahap ini dilakukan peninjauan terhadap nilai ekstrem (outliers) pada kolom numerik dalam dataset. Outlier adalah nilai yang menyimpang jauh dari sebagian besar data lainnya dan dapat memengaruhi akurasi hasil analisis jika tidak ditangani dengan tepat. Pengecekan outlier dilakukan menggunakan metode IQR (Interquartile Range), yaitu dengan menghitung batas bawah (Q1 − 1,5×IQR) dan batas atas (Q3 + 1,5×IQR). Nilai yang berada di luar kedua batas tersebut dikategorikan sebagai outlier.

```
# Deteksi outlier pada kolom release_year menggunakan metode IQR
q1 = df['release_year'].quantile(0.25)
q3 = df['release_year'].quantile(0.75)
iqr = q3 - q1
lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr

outliers = df[(df['release_year'] < lower) | (df['release_year'] > upper)]
pct = len(outliers) / len(df) * 100

print(f"Batas bawah IQR : {lower:.0f}")
print(f"Batas atas IQR  : {upper:.0f}")
print(f"Jumlah outlier  : {len(outliers)} ({pct:.2f}%)")
print("\nCatatan: Outlier berupa film-film lawas (1925-1970an) — valid secara konteks, tidak dihapus.")
```

```
Batas bawah IQR : 2004
Batas atas IQR  : 2028
Jumlah outlier  : 719 (8.16%)

Range release_year: 1925 - 2021

Catatan: Outlier berupa film-film lawas (1925-1970an) — valid secara konteks, tidak dihapus.
```

Gambar 2.7 Outliers Value

2.3. Preprocessing (Data Cleaning)

Berdasarkan hasil verifikasi kualitas data, dilakukan beberapa langkah preprocessing untuk mempersiapkan data yang bersih dan siap dianalisis:

Tabel 2.3 Tabel Strategi Pembersihan

Masalah	Kolom Terdampak	Strategi Penanganan
Nilai salah di kolom rating	rating, duration	Pindahkan nilai menit dari kolom rating ke kolom duration, set rating menjadi NaN
Tipe data tidak sesuai	date_added	Konversi ke datetime menggunakan pd.to_datetime()
Missing values	director, country	Isi dengan nilai 'Unknown' agar tidak error saat pemrosesan
Missing values	rating	Isi dengan 'NR' (Not Rated)
Fitur tambahan	Kolom baru	Buat kolom year_added, month_added, primary_country
Masalah	Kolom Terdampak	Strategi Penanganan

Kode preprocessing yang dijalankan:

```
df_clean = df.copy()

# 1. Fix nilai salah di kolom rating
mask_wrong = df_clean['rating'].isin(['74 min', '84 min', '66 min'])
df_clean.loc[mask_wrong, 'duration'] = df_clean.loc[mask_wrong, 'rating']
df_clean.loc[mask_wrong, 'rating'] = np.nan
print(f'Fixed {mask_wrong.sum()} nilai salah di kolom rating')

# 2. Konversi date_added ke datetime
df_clean['date_added'] = pd.to_datetime(df_clean['date_added'].str.strip(), format='%B %d, %Y',
errors='coerce')
df_clean['year_added'] = df_clean['date_added'].dt.year
df_clean['month_added'] = df_clean['date_added'].dt.month

# 3. Isi missing values
df_clean['director'] = df_clean['director'].fillna('Unknown')
df_clean['country']  = df_clean['country'].fillna('Unknown')
df_clean['rating']   = df_clean['rating'].fillna('NR')

# 4. Ekstrak primary country dan primary genre
df_clean['primary_country'] = df_clean['country'].str.split(',').str[0].str.strip()
df_clean['primary_genre']   = df_clean['listed_in'].str.split(',').str[0].str.strip()

print(f'Shape setelah cleaning: {df_clean.shape}')

# Simpan dataset bersih
df.to_csv('netflix_titles(Bersih).csv', index=False)
```

2.3.1. Menyimpan Dataset Bersih

Setelah seluruh tahap pembersihan dan persiapan data selesai, dataset yang telah bersih disimpan ke file baru untuk digunakan pada tahap visualisasi dan pembuatan dashboard.

```
df.to_csv('netflix_titles(bersih).csv', index=False)
```

2.4. Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) adalah tahap analisis awal yang bertujuan untuk menemukan pola, anomali, dan hubungan dalam data menggunakan statistik ringkas dan visualisasi. EDA dilakukan dengan 4 pendekatan: Comparison, Composition, Distribution, dan Relationship. Setiap visualisasi dilengkapi insight dan rekomendasi tindakan.

2.4.1. Movie vs TV Show (Bar Chart)

Aktivitas: Membandingkan jumlah konten berdasarkan tipe (Movie vs TV Show).

Tujuan: Mengidentifikasi tipe konten mana yang paling dominan di Netflix.

Visualisasi: Bar Chart

```
type_counts = df['type'].value_counts()

plt.figure(figsize=(7, 5))
bars = plt.bar(type_counts.index, type_counts.values,
               color=['#E50914', '#221F1F'], width=0.5, edgecolor='white')
plt.title('Jumlah Movie vs TV Show di Netflix', fontsize=14, fontweight='bold')
plt.xlabel('Tipe Konten')
plt.ylabel('Jumlah')
plt.ylim(0, 7500)
for i, v in enumerate(type_counts.values):
    plt.text(i, v + 80, f'{v:,}\n({v/len(df)*100:.1f}%)',
             ha='center', fontweight='bold', fontsize=11)
plt.tight_layout()
plt.show()
```

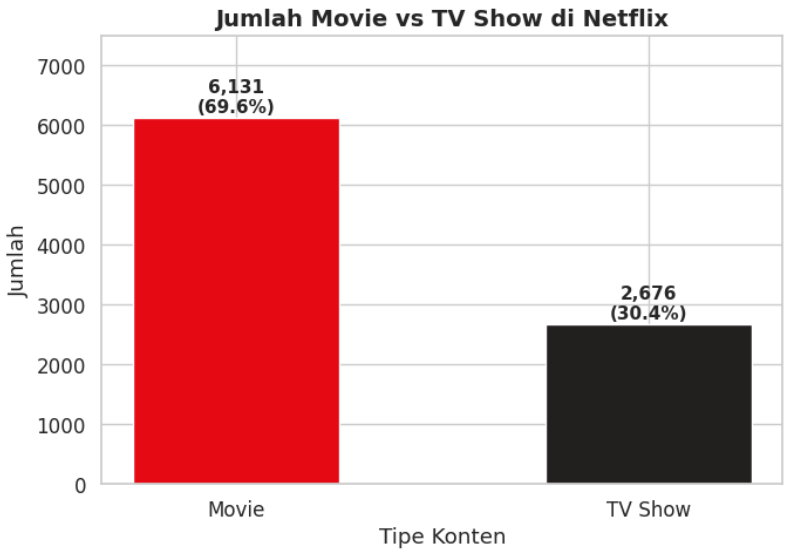

Gambar 2.8 Jumlah Movie vs TV Show di Netflix

a. Insight:

- Movie jauh mendominasi dengan 6.131 judul (69.6%) dibanding TV Show yang hanya 2.676 judul (30.4%).
- Rasio hampir 7:3 — artinya dari setiap 10 konten Netflix, 7 di antaranya adalah film.

b. Rekomendasi Tindakan:

- Bagi kreator konten, memproduksi film memiliki peluang lebih besar untuk masuk katalog Netflix.
- Bagi pengguna yang suka series panjang, Netflix mungkin kurang memuaskan — bisa diversifikasi ke platform lain untuk TV Show.
- Netflix bisa menambah porsi TV Show untuk meningkatkan retensi pengguna karena series cenderung membuat penonton kembali.

2.4.2. Top 10 Genre Terpopuler Transaksi per Negara (Bar Chart)

Aktivitas: Membandingkan jumlah konten berdasarkan genre.

Tujuan: Mengidentifikasi genre mana yang paling banyak tersedia di Netflix.

Visualisasi: Horizontal Bar Chart

```
genre_counts = df['listed_in'].str.split(', ').explode().value_counts().head(10)

plt.figure(figsize=(9, 6))
```

```
bars = plt.barh(genre_counts.index[::-1], genre_counts.values[::-1],
                color=sns.color_palette('viridis', 10), edgecolor='white')
plt.title('Top 10 Genre Terpopuler di Netflix', fontsize=14, fontweight='bold')
plt.xlabel('Jumlah Konten')
plt.ylabel('Genre')
for i, v in enumerate(genre_counts.values[::-1]):
    plt.text(v + 15, i, str(v), va='center', fontsize=10, fontweight='bold')
plt.xlim(0, 3200)
plt.tight_layout()
plt.show()
```

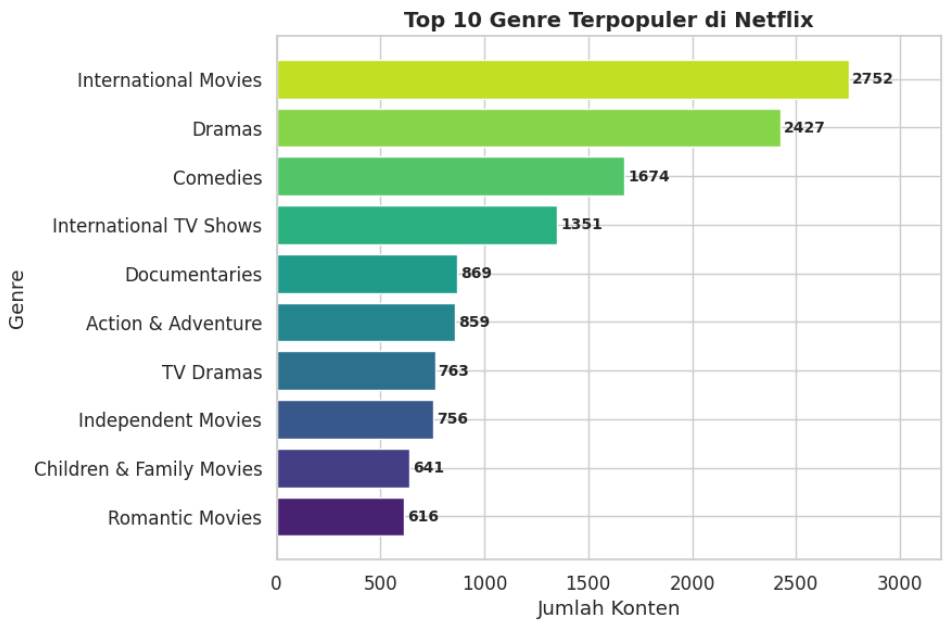

Gambar 2.9 Top 10 Genre Terpopuler di Netflix

a. Insight:

- International Movies menjadi genre terbanyak dengan 2.752 konten, menunjukkan Netflix aktif menghadirkan konten dari luar Amerika.
- Dramas (2.427) dan Comedies (1.674) konsisten menjadi genre favorit lintas budaya.
- Genre Action & Adventure dan Documentaries juga cukup kuat dengan masing-masing ~859 dan ~869 konten.

b. Rekomendasi Tindakan

- Produser konten Indonesia berpeluang besar masuk Netflix karena permintaan International Movies sangat tinggi.

- Jika ingin membuat konten yang mudah diterima pasar global, fokus pada genre Drama atau Comedy karena paling universal.
- Netflix bisa mempertimbangkan untuk memperkuat genre niche (Sport, Sci-Fi) agar membedakan diri dari kompetitor.

2.4.3. Proporsi Negara Produksi (Pie Chart)

Aktivitas: Menampilkan proporsi kontribusi negara produksi terhadap total konten Netflix.

Tujuan: Melihat seberapa besar dominasi negara tertentu dalam katalog Netflix secara keseluruhan.

Visualisasi: Pie Chart

```
df_country = df[df['primary_country'] != 'Unknown']
top_c = df_country['primary_country'].value_counts()
top8  = top_c.head(8)
others_val = top_c.iloc[8:].sum()

pie_data   = list(top8.values) + [others_val]
pie_labels = list(top8.index)  + ['Others']
colors_pie = sns.color_palette('Set2', len(pie_data))
explode    = [0.05] * len(pie_data)
explode[0] = 0.12

plt.figure(figsize=(8, 8))
plt.pie(pie_data, labels=pie_labels, autopct='%1.1f%%',
        colors=colors_pie, explode=explode, startangle=140,
        textprops={'fontsize': 10})
plt.title('Komposisi Negara Produksi Konten Netflix', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()
```

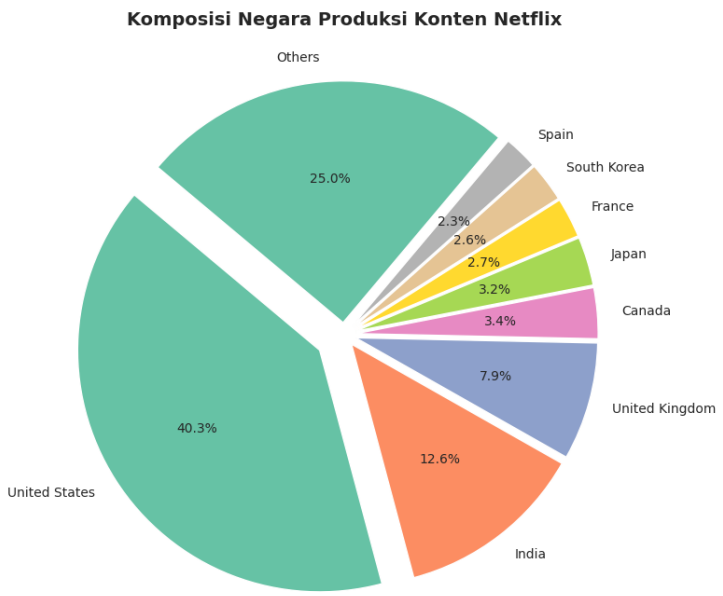

Gambar 2.10 Komposisi Negara Produksi Konten Netflix

a. **Insight:**

- United States mendominasi dengan proporsi terbesar (~40%), hampir setara dengan gabungan semua negara lainnya.
- India menyumbang porsi signifikan (~12%), mencerminkan besarnya industri film Bollywood.
- Negara-negara Asia (Japan, South Korea) dan Eropa (UK) juga memiliki representasi yang cukup.

b. **Rekomendasi Tindakan**

- Netflix perlu menjaga keseimbangan agar tidak terlalu US-sentris demi menjaga pengguna di negara berkembang.
- Kategori 'Others' yang besar (~28%) menunjukkan potensi ekspansi konten dari negara-negara yang belum terwakili.
- Strategi 'local content' seperti yang dilakukan Netflix Indonesia berpotensi meningkatkan engagement pengguna lokal.

2.4.4. Top 10 Negara Produksi (Bar Chart)

Aktivitas: Membandingkan jumlah absolut konten dari 10 negara produksi teratas.

Tujuan: Melihat ranking negara berdasarkan jumlah konten yang diproduksi secara lebih detail.

Visualisasi: Bar Chart

```
df_country = df[df['primary_country'] != 'Unknown']
top10_c = df_country['primary_country'].value_counts().head(10)

plt.figure(figsize=(10, 5))
bars = plt.bar(top10_c.index, top10_c.values,
               color=sns.color_palette('Set2', 10), edgecolor='white')
plt.title('Top 10 Negara Produksi Konten Netflix', fontsize=14, fontweight='bold')
plt.xlabel('Negara')
plt.ylabel('Jumlah Konten')
plt.xticks(rotation=40, ha='right')
for i, v in enumerate(top10_c.values):
    plt.text(i, v + 20, str(v), ha='center', fontsize=10, fontweight='bold')
plt.ylim(0, max(top10_c.values) * 1.15)
plt.tight_layout()
plt.show()
```

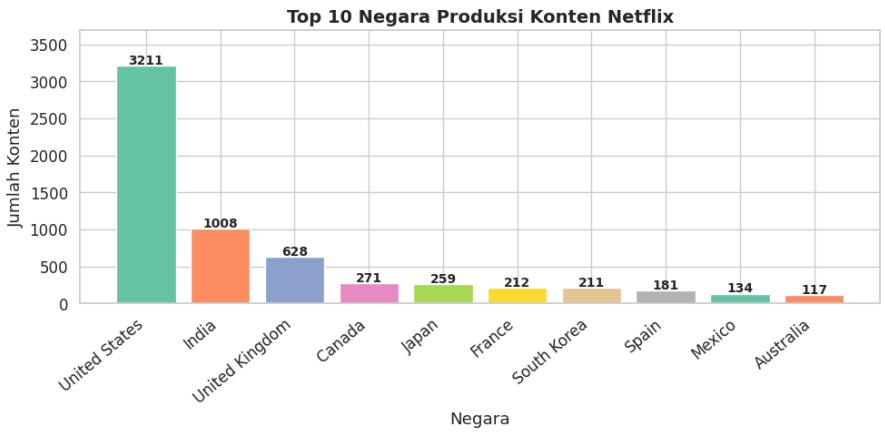

Gambar 2.11 Top 10 Negara Produksi Konten Netflix

a. Insight

- United States (2.818) memimpin jauh dibanding negara lain — hampir 3x lipat India di posisi kedua.
- South Korea (199) masuk top 5 meskipun negara kecil, didorong popularitas K-Drama dan K-Movie global.
- Kesenjangan antara US (2.818) dan posisi ke-10 (Egypt ~106) sangat besar, menunjukkan dominasi yang ekstrem.
-

c. **Rekomendasi Tindakan**

- Negara dengan produksi rendah seperti Indonesia, Brazil, Nigeria memiliki ruang besar untuk tumbuh di Netflix.
- Keberhasilan South Korea bisa menjadi model — investasi di konten berkualitas tinggi bisa melampaui keterbatasan ukuran negara.
- Netflix bisa menerapkan kuota konten lokal per wilayah untuk mempercepat pertumbuhan di negara berkembang.

2.4.5. Distribusi Tahun Rilis Konten (Histogram)

Aktivitas: Menganalisis sebaran tahun rilis konten Netflix.

Tujuan: Mengetahui mayoritas konten berasal dari era mana.

Visualisasi: Histogram

```
df_modern = df[df['release_year'] >= 1990]
median_year = int(df['release_year'].median())

plt.figure(figsize=(10, 5))
plt.hist(df_modern['release_year'], bins=32, color='#E50914', edgecolor='white', alpha=0.85)
plt.axvline(median_year, color='black', linestyle='--', linewidth=2,
            label=f'Median: {median_year}')
plt.title('Distribusi Tahun Rilis Konten Netflix (1990-2021)', fontsize=14, fontweight='bold')
plt.xlabel('Tahun Rilis')
plt.ylabel('Jumlah Konten')
plt.legend(fontsize=11)
plt.tight_layout()
plt.show()
```

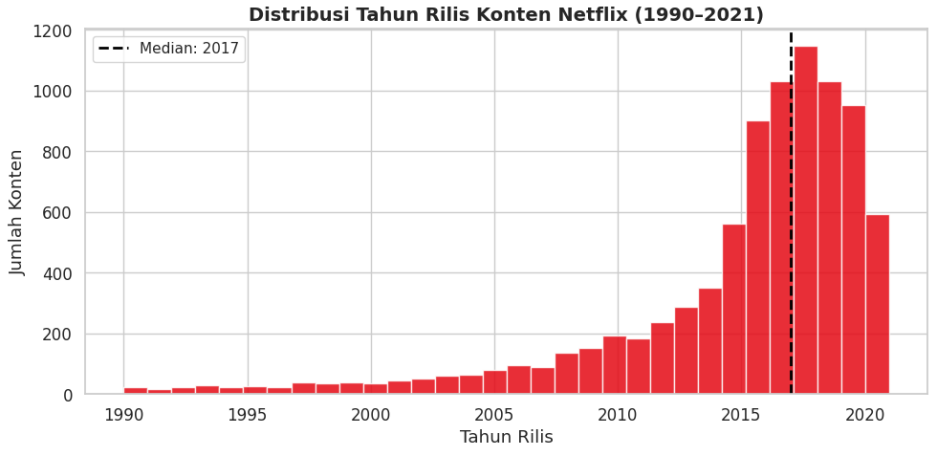

Gambar 2.12 Distribusi Tahun Rilis Konten Netflix (1990-2021)

a. Insight:

- Distribusi berbentuk right-skewed — konten Netflix didominasi oleh produksi terbaru, terutama 2015-2021.
- Median tahun rilis adalah 2017, artinya setengah dari seluruh konten dirilis di tahun 2017 ke atas.
- Konten lama (sebelum 2000) sangat sedikit, menandakan Netflix tidak terlalu fokus pada arsip klasik.

b. Rekomendasi Tindakan

- Pengguna yang suka film klasik mungkin perlu mencari platform lain seperti Criterion Channel atau Mubi.
- Netflix bisa menambah koleksi film klasik sebagai daya tarik segmen penonton yang lebih tua.
- Produsen konten sebaiknya mengikuti tren konten baru karena Netflix sangat mendominasi konten era modern.

2.4.6. Tren Penambahan Konten per Tahun (Line Chart)

Aktivitas: Menganalisis tren jumlah konten yang ditambahkan ke Netflix per tahun.

Tujuan: Melihat pertumbuhan platform Netflix dari waktu ke waktu.

Visualisasi: Line Chart

```
year_added = df.groupby('year_added').size().reset_index(name='count')
year_added = year_added[(year_added['year_added'] >= 2008) &
                        (year_added['year_added'] <= 2021)].copy()

plt.figure(figsize=(11, 5))
plt.plot(year_added['year_added'], year_added['count'],
         marker='o', color='#221F1F', linewidth=2.5, markersize=8)
plt.fill_between(year_added['year_added'], year_added['count'],
                 alpha=0.2, color='#E50914')
plt.title('Tren Penambahan Konten Netflix per Tahun', fontsize=14, fontweight='bold')
plt.xlabel('Tahun')
plt.ylabel('Jumlah Konten Ditambahkan')
plt.xticks(year_added['year_added'].astype(int))
for _, row in year_added.iterrows():
    plt.text(row['year_added'], row['count'] + 18,
             str(int(row['count'])), ha='center', fontsize=9, fontweight='bold')
plt.tight_layout()
plt.show()
```

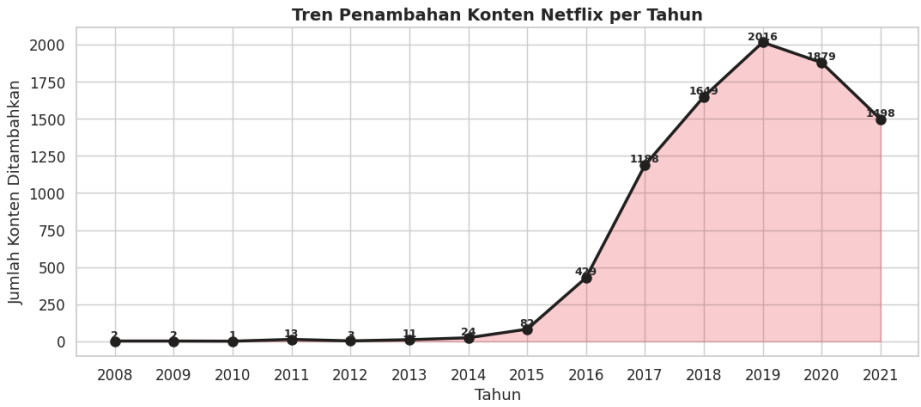

Gambar 2.13 Tren Penambahan Konten Netflix per Tahun

a. Insight

- Pertumbuhan konten sangat pesat dari 2015 (756 konten) hingga puncaknya di 2019 (1.497 konten) — naik hampir 2x lipat dalam 4 tahun.
- Terjadi penurunan tajam di 2020 dan 2021, kemungkinan besar akibat pandemi COVID-19 yang menghambat produksi.
- Sebelum 2015, pertumbuhan sangat lambat — menandakan Netflix baru serius ekspansi konten di pertengahan 2010-an.

b. Rekomendasi Tindakan

- Netflix perlu strategi recovery pasca pandemi untuk mengembalikan laju penambahan konten ke angka puncak 2019.
- Investasi di konten original (Netflix Original) bisa menjadi solusi karena tidak bergantung pada studio eksternal.
- Data 2021 yang masih rendah bisa juga berarti dataset belum lengkap — perlu diverifikasi dengan sumber terkini.

2.4.7. Rating Konten berdasarkan Tipe (Grouped Bar Chart)

Aktivitas: Menganalisis hubungan antara rating konten dengan tipe (Movie vs TV Show).

Tujuan: Mengetahui apakah Movie dan TV Show memiliki pola rating yang berbeda.

Visualisasi: Grouped Bar Chart

```
valid_ratings = ['TV-MA', 'TV-14', 'TV-PG', 'R', 'PG-13', 'TV-Y7', 'TV-Y', 'PG', 'TV-G', 'G']
df_rated = df[df['rating'].isin(valid_ratings)]
rating_type = df_rated.groupby(['rating', 'type']).size().unstack(fill_value=0)
rating_type = rating_type.loc[[r for r in valid_ratings if r in rating_type.index]]

plt.figure(figsize=(11, 5))
rating_type.plot(kind='bar', color=['#221F1F', '#E50914'],
            edgecolor='white', width=0.7,
            ax=plt.gca())
plt.title('Distribusi Rating berdasarkan Tipe Konten', fontsize=14, fontweight='bold')
plt.xlabel('Rating')
plt.ylabel('Jumlah Konten')
plt.xticks(rotation=30)
```

```
plt.legend(title='Tipe Konten')
plt.tight_layout()
plt.show()
```

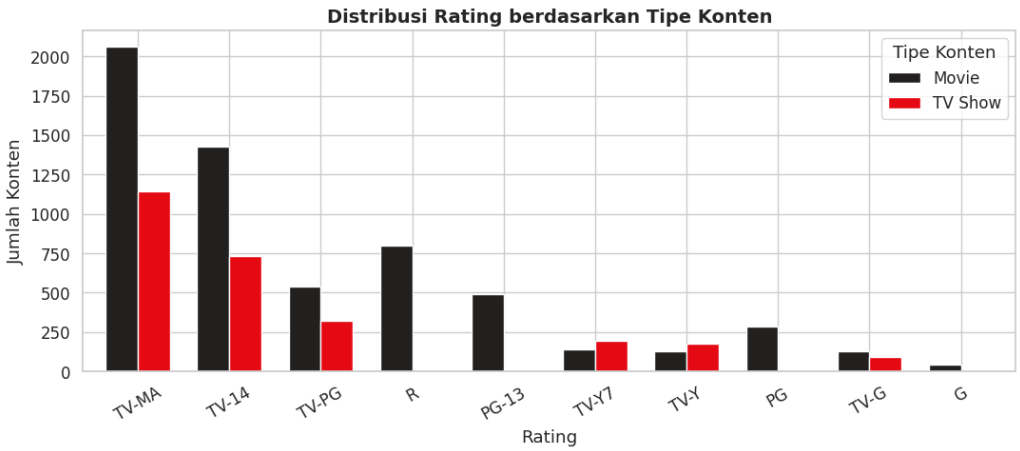

Gambar 2.14 Distribusi Rating berdasarkan Tipe Konten

a. Insight

- Rating TV-MA (dewasa) sangat mendominasi, terutama dari TV Show — ini adalah rating tertinggi di Netflix.
- Movie lebih banyak menggunakan rating film standar (R, PG-13), sedangkan TV Show mayoritas menggunakan rating TV (TV-MA, TV-14).
- Rating ramah anak seperti TV-Y, TV-G, G sangat sedikit — Netflix bukan platform utama untuk konten anak-anak.

b. Rekomendasi Tindakan

- Orang tua yang ingin menggunakan Netflix untuk anak perlu aktif menggunakan fitur parental control.
- Netflix bisa memperbanyak konten kids (TV-Y, G) untuk bersaing dengan Disney+ yang lebih kuat di segmen ini.
- Pengiklan yang menyasar remaja dan dewasa muda sebaiknya fokus beriklan di konten TV-MA dan TV-14.

2.4.8. Heatmap Genre vs Rating

Aktivitas: Menganalisis hubungan antara genre dengan rating menggunakan heatmap.

Tujuan: Menemukan pola kombinasi genre-rating yang paling umum di Netflix.

Visualisasi: Heatmap

```
top_genres_list  = ['Dramas', 'Comedies', 'Action & Adventure',
                    'Documentaries', 'International Movies']
top_ratings_list = ['TV-MA', 'TV-14', 'R', 'PG-13', 'TV-PG', 'PG', 'TV-Y', 'TV-G']

heatmap_data = {}
for genre in top_genres_list:
    row = {}
    for rating in top_ratings_list:
        count = len(df[(df['listed_in'].str.contains(genre, na=False)) &
                       (df['rating'] == rating)])
        row[rating] = count
    heatmap_data[genre] = row

hm_df = pd.DataFrame(heatmap_data).T

plt.figure(figsize=(10, 5))
sns.heatmap(hm_df, annot=True, fmt='d', cmap='YlOrRd',
            linewidths=0.5, linecolor='white')
plt.title('Heatmap: Jumlah Konten per Genre dan Rating', fontsize=14, fontweight='bold')
plt.xlabel('Rating')
plt.ylabel('Genre')
plt.tight_layout()
plt.show()
```

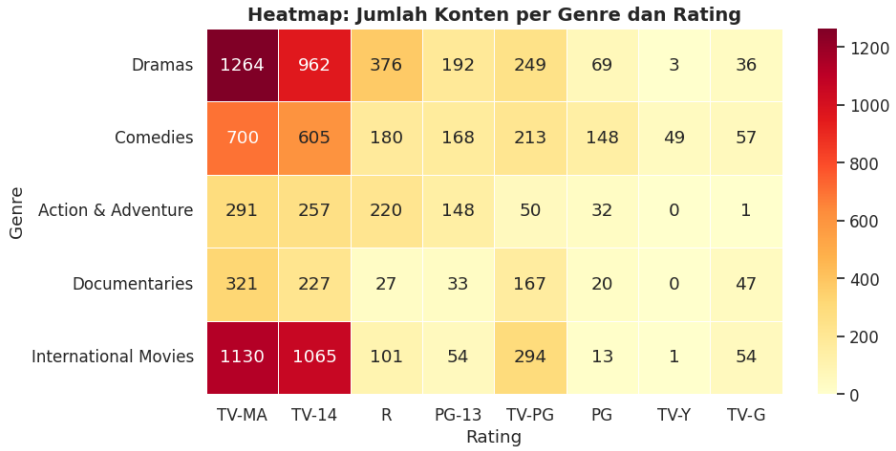

Gambar 2.15 Jumlah Konten per Genre dan Rating

a. Insight

- Dramas + TV-MA adalah kombinasi paling dominan — drama dewasa menjadi konten andalan Netflix.
- Comedies tersebar cukup merata di berbagai rating, menandakan genre ini lebih inklusif untuk semua usia.
- Documentaries cenderung memiliki rating TV-MA dan TV-14 — menunjukkan topik yang dibahas serius dan dewasa.
- International Movies dengan rating TV-MA dan TV-14 sangat banyak, menunjukkan konten internasional umumnya ditujukan untuk dewasa.

b. Rekomendasi Tindakan

- Kreator yang ingin kontennya masuk Netflix sebaiknya membuat Drama dengan rating TV-MA karena ini kombinasi paling diminati platform.
- Comedy yang family-friendly (PG/TV-PG) masih memiliki celah yang bisa diisi karena jumlahnya relatif kecil.
- Platform dapat menggunakan pola ini untuk sistem rekomendasi konten — pengguna yang suka Drama TV-MA cenderung juga suka Thriller atau Action dewasa.

BAB III
PENUTUP

3.1. Kesimpulan

Berdasarkan Exploratory Data Analysis yang telah dilakukan pada dataset Netflix Titles (8.807 baris, 12 kolom), diperoleh beberapa kesimpulan penting. Dari sisi perbandingan (Comparison), Movie mendominasi katalog Netflix dengan 69.6% dari total konten, sementara genre International Movies, Dramas, dan Comedies menjadi tiga genre terbanyak yang menunjukkan Netflix aktif menghadirkan konten global lintas genre.

Dari sisi komposisi (Composition), United States menjadi negara produsen konten terbesar dengan kontribusi sekitar 36%, diikuti India sekitar 12%. Meskipun katalog Netflix cukup beragam, dominasi Amerika Serikat masih sangat besar dengan gap yang signifikan dibanding negara-negara lainnya.

Dari sisi distribusi (Distribution), mayoritas konten dirilis di era modern 2015–2021 dengan median tahun rilis pada 2017. Penambahan konten mencapai puncaknya pada tahun 2019 dengan 1.497 judul, namun kemudian mengalami penurunan yang signifikan akibat dampak pandemi COVID-19 yang menghambat proses produksi secara global.

Dari sisi hubungan (Relationship), Netflix secara jelas menyasar segmen penonton dewasa dengan TV-MA sebagai rating yang paling dominan dalam katalog. Genre Dramas dengan rating tinggi menjadi konten andalan platform, sementara genre Comedy bersifat paling inklusif karena tersebar merata di berbagai kategori rating.

3.2. Saran

Berdasarkan proses analisis yang telah dilakukan, penulis menyadari masih terdapat beberapa keterbatasan dalam penelitian ini. Kedepannya, penulis berharap dapat menggunakan data yang lebih terkini mencakup periode 2022–2024 agar analisis tren dan pola konten yang dihasilkan lebih relevan dan akurat. Penulis juga berharap dapat memperluas jenis visualisasi yang digunakan, seperti map chart untuk analisis geografis distribusi negara produksi dan scatter plot untuk mengeksplorasi hubungan antar variabel secara lebih mendalam. Penulis juga akan lebih memperhatikan dokumentasi setiap tahapan analisis secara bertahap agar laporan yang dihasilkan lebih terstruktur, akurat, dan mudah dipahami oleh pembaca.